

# Régression linéaire

Eric Marcon

03 February 2024

Régression  
linéaire

Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova

# Régression linéaire simple

## Données du projet de dendrométrie 2020, Mont Ventoux.

```
read_csv2("data/Inv_GEEFT_Ventoux_09-2020.csv") |>
  rename(
    espece = Espèce,
    diametre = `Diamètre (cm)`,
    hauteur = `Hauteur réelle (m)`
  ) |>
  mutate(
    espece = case_match(
      espece,
      "P" ~ "Pin",
      "C" ~ "Cèdre"
    )
  ) -> ventoux
```

# Graphique hauteur ~ diamètre

Régression  
linéaire

Eric Marcon


Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova

```
ventoux |>
  ggplot(aes(x = diametre, y = hauteur)) +
  geom_point(aes(col = espece)) +
  geom_smooth(method = "lm")
```



Modèle linéaire simple :


$$Y = \beta_0 + \beta_1 X + E$$

$Y$  et  $X$  sont des vecteurs :  $Y = \{y_i\}$  est l'ensemble des observations. Par abus d'écriture,  $Y$  est aussi la variable aléatoire dont les  $y_i$  sont des réalisations.

Vocabulaire : variable expliquée, exogène, coefficients, constante (intercept)...

$E = \{\epsilon_i\}$  est l'erreur du modèle.  $E \sim \mathcal{N}(0, \sigma^2)$

Le modèle prédit une densité de probabilité des valeurs de  $Y$  pour toute valeur de  $X$  distribuée normalement autour de la droite de régression.



- Indépendance des erreurs :  $\text{Cov}(\epsilon_i, \epsilon_j) = 0$ . Assurée par le design expérimental.
- Exogénéité :  $X$  n'est pas corrélé à  $E$ .
- Homoscédasticité : la variance de l'erreur est constante sur l'étendue de  $X$ .
- Normalité des termes d'erreur :  $E \sim \mathcal{N}(0, \sigma^2)$ .

Générer les données du modèle.

Coefficients :

```
beta_0 <- 1  
beta_1 <- 0.5  
sigma <- 1
```


Tirage :

```
n <- 100  
x <- runif(n, min = 5, max = 15)  
# Jeu de points  
mod_l1 <- tibble(x, y = rnorm(n, mean = beta_0 + beta_1*x, sd = sigma))
```



Commencer par une figure.

```
mod_l1 |>
  ggplot(aes(x = x, y = y)) + geom_point() + geom_smooth(method = lm)
```



La fonction `lm()` du package *stats* estime le modèle et permet de tester les hypothèses.


```
mod_l1_lm <- lm(y ~ x, data = mod_l1)
```

Syntaxe de la formule :

- variable expliquée à gauche, covariables à droite de `~`
- constante implicite  $y \sim x$  est identique à  $y \sim 1 + x$  alors que  $y \sim 0 + x$  force la constante à 0.
- possibilité de transformer les variables :  $\log(y) \sim I(x^2)$  (Attention :  $\log(y) \sim x^2$  est interprété comme l'interaction de  $x$  avec lui-même, c'est-à-dire  $x$ )

## Graphique $E \sim Y^*$


```
plot(mod_l1_lm, which = 1)
```



Les erreurs doivent être centrée sur 0 et uniformément réparties.

## Graphique quantile - quantile (`?qqplot`)

```
plot(mod_l1_lm, which = 2)
```



La non-normalité des résidus implique la non-normalité des estimateurs des coefficients.

Utiliser le test de Shapiro-Wilk :

```
mod_l1_lm |> residuals() |> shapiro.test()
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  residuals(mod_l1_lm)  
## W = 0.98344, p-value = 0.2439
```

La p-value est la probabilité de se tromper en rejetant l'hypothèse nulle de normalité des données. Attention : la puissance du test augmente avec la taille de l'échantillon (limité à 5000).

# Test de Kolmogorov-Smirnov

Régression  
linéaire

Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova

Teste l'hypothèse que deux échantillons sont issus de la même distribution :


```
mod_l1_lm |> residuals() %>% ks.test(rnorm(length(.), 0, var(.)))

##
## Asymptotic two-sample Kolmogorov-Smirnov
## test
##
## data:  . and rnorm(length(.), 0, var(.))
## D = 0.11, p-value = 0.5806
## alternative hypothesis: two-sided
```

Plus général que Shapiro-Wilk.

→ tester un tirage dans une loi uniforme contre une distribution normale. Combien de valeurs faut-il pour rejeter  $H_0$  ?

```
plot(mod_l1_lm, which = 5)
```



Les points avec fort effet de levier forte erreur ( $\rightarrow$  grande distance de Cook) posent problème.

## Affaire d'expérience.

- Éliminer les points (réellement) aberrants ;
- Transformer  $Y$  si :
  - la relation n'est pas linéaire (ex.: quadratique) ;
  - l'erreur augmente avec  $Y^*$  ( $\rightarrow$  racine carrée ou logarithme).
- Revoir les hypothèses à l'origine du modèle, le design expérimental...



# Interprétation des résultats : summary

Régression  
linéaire

Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple


Régression sur  
les rangs

Ancova

```
##
## Call:
## lm(formula = y ~ x, data = mod_l1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.51229 -0.69782 -0.02673  0.68502  2.22763
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.55838     0.37138   4.196 5.97e-05
## x            0.44729     0.03525  12.689 < 2e-16
##
## (Intercept) ***
## x            ***
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.042 on 98 degrees of freedom
## Multiple R-squared:  0.6216, Adjusted R-squared:  0.6178
## F-statistic: 161 on 1 and 98 DF, p-value: < 2.2e-16
```

La statistique F décrit la probabilité que le modèle n'explique rien.

Modèle nul:  $Y = \bar{Y} = \beta_0$



$R^2$  mesure la proportion de la variance de  $Y$  expliquée par le modèle :

$$R^2 = \frac{\text{Var}(Y^*)}{\text{Var}(Y)} = 1 - \frac{\sigma}{\text{Var}(Y)}$$

→ Que devient  $R^2$  en doublant  $\sigma$  ? Estimer rapidement puis re-simuler le modèle pour vérifier.

$R^2$  ajusté pénalise le  $R^2$  par le nombre de paramètres du modèle.

Les degrés de liberté sont le nombre d'observations moins le nombre de paramètres moins 1.

Les coefficients sont estimés par la méthode des moindres carrés : minimisation des écarts

$$\sum (y_i - y_i^*)^2$$

.

Résultat identique à la maximisation de la vraisemblance

$$\prod f(\epsilon_i)$$

où  $f(\cdot)$  est la densité de  $\mathcal{N}(0, \sigma^2)$ .

L'estimateur de chaque coefficient est sa valeur la plus probable.

L'estimateur est distribué normalement (quand  $E$  est normal) :

$$\hat{\beta}_1 \sim \mathcal{N}(0.447, 0.0352^2)$$

Un test de Student donne la probabilité de se tromper en affirmant que l'estimateur n'est pas nul.

Un bon modèle a un grand  $R^2$  et des petites p-values.

- $R^2$  diminue avec la variance de l'erreur ;
- L'écart-type des estimateur diminue comme  $\sqrt{n}$ .

Mais les deux dépendent du design expérimental.

Quadrupler l'effort d'échantillonnage divise par deux l'intervalle de confiance

```
mod_l1x4 <- tibble(  
  x = rnorm(n * 4, mean = 10, sd = 2), # x est calculé avant y  
  y = rnorm(n * 4, mean = beta_0 + beta_1 * x, sd = sigma) # y utilise x  
)  
mod_l1x4_lm <- lm(y ~ x, data = mod_l1x4)  
summary(mod_l1x4_lm)$coefficients
```

```
##              Estimate Std. Error   t value  
## (Intercept) 1.4740364 0.26412629  5.580801  
## x           0.4558641 0.02579445 17.672952  
##              Pr(>|t|)  
## (Intercept) 4.434776e-08  
## x           5.182547e-52
```

Choix économique.

Retirer les valeurs intermédiaires de  $X$  augmente le  $R^2$  (*design factoriel*) alors que  $\sigma$  ne change pas.

```
mod_l1x4 |>
  filter(x < 6 | x > 14) %>% # pas /> pour "data = ."
  lm(y ~ x, data = .) |>
  summary() |>
  pluck("r.squared")
```

```
## [1] 0.8281414
```

contre 0.4396996 avec toutes les données.



Régression  
linéaire

Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova

Le  $R^2$  d'un modèle avec des données individuelles est plus faible qu'avec des données agrégées.

- Estimer le modèle hauteur  $\sim$  diamètre des données Ventoux.
- Regrouper les données par espèce.
- Estimer le modèle à nouveau.

Considérer  $R^2$  et p-values en fonction du modèle :

- beaucoup de données individuelles  $\rightarrow$  faible  $R^2$  mais petites p-values pour montrer l'influence d'un facteur ;
- possibilité d'un très grand  $R^2$  sans aucun coefficient significatif si peu de points ;
- un grand  $R^2$  et des petites p-values permettent de faire des prédictions.

Régression  
linéaire

Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova


`predict()` permet d'extrapoler le modèle.

```
mod_l1_lm |> predict(newdata = data.frame(x = 5:10))
```

```
##           1           2           3           4           5
## 3.794805 4.242090 4.689375 5.136661 5.583946
##           6
## 6.031231
```

## Ajout des points sur la figure :

```
# Estimation du modèle
mod_l1 |>
  ggplot(aes(x, y)) + geom_point() + geom_smooth(method = lm) ->
  mod_l1_ggplot
# Choix des x pour lesquels y est à prédire
mod_l1_predict <- data.frame(x = 5:10)
# Ajout des prédictions
mod_l1_predict$y <- predict(mod_l1_lm, newdata = mod_l1_predict)
# Ajout des points à la figure précédente
mod_l1_ggplot +
  geom_point(data = mod_l1_predict, aes(x = x, y = y), col = "red")
```



# Intervalles de confiance et de prédiction

Régression  
linéaire

Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova

La zone grisée de `geom_smooth` est l'intervalle de confiance de l'espérance de  $Y|X$ , c'est-à-dire de la moyenne des prédictions. Il est bien plus étroit que l'intervalle de prédiction, qui correspond à 95% des prédictions :

```
mod_l1_predict <- data.frame(  
  x = seq(from = min(mod_l1$x), to = max(mod_l1$x), length.out = 50)  
)  
mod_l1_predict <- cbind(  
  mod_l1_predict,  
  predict(  
    mod_l1_lm,  
    newdata = mod_l1_predict,  
    interval = "prediction"  
  )  
)  
mod_l1_ggplot +  
  geom_ribbon(  
    data = mod_l1_predict,  
    aes(y = fit, ymin = lwr, ymax = upr),  
    alpha = 0.3  
  ) -> mod_l1_ggplot_predict
```

# Intervalles de confiance et de prédiction

Régression  
linéaire


Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova



# Régression linéaire multiple

## Modèle linéaire multiple :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + E$$

$Y$  et  $X_j$  sont des vecteurs :  $X_1 = \{x_{i,1}\}$  est l'ensemble des valeurs du premier prédicteur (= variable explicative, variable exogène ou covariable).



Multidimensionnelle donc plus difficile.

Le dimension de  $Y$  est égale au nombre de covariables moins 1:  
le modèle linéaire réduit la dimension des données.


Ajout d'un coefficient à l'exemple précédent :

```
beta_0 <- 1
beta_1 <- 0.5
beta_2 <- 2
sigma <- 5
```

Tirage :

```
n <- 100
x_1 <- runif(n, min = 5, max = 15)
x_2 <- runif(n, min = 0, max = 10)
# Jeu de points
mod_l2 <- tibble(
  x_1, x_2,
  y = rnorm(n, mean = beta_0 + beta_1*x_1 + beta_2*x_2, sd = sigma)
)
```

```
mod_12_lm <- lm(y ~ x_1 + x_2, data = mod_12)
```



En plus des précédentes :

- Non colinéarité des covariables.

Si une des covariables est une combinaison linéaire des autres, le modèle ne peut pas être estimé.

En pratique, les covariables doivent être aussi peu corrélées que possible.

On peut tester l'effet de l'interaction de deux variables :

```
lm(y ~ x_1 + x_2 + x_1*x_2, data = mod_12) |> summary()
```

```
##
## Call:
## lm(formula = y ~ x_1 + x_2 + x_1 * x_2, data = mod_12)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.8144  -3.7527   0.0555   3.4683  14.3491
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   6.07576    3.40857   1.782   0.0778
## x_1           0.07438    0.35391   0.210   0.8340
## x_2           0.96892    0.65142   1.487   0.1402
## x_1:x_2       0.08070    0.06674   1.209   0.2296
##
## (Intercept) .
## x_1
## x_2
## x_1:x_2
## ---
```

Il est possible de standardiser toutes les variables pour comparer les effets des covariables.

```
lm(scale(y) ~ 0 + scale(x_1) + scale(x_2), data = mod_l2) |> summary()
```

```
##
## Call:
## lm(formula = scale(y) ~ 0 + scale(x_1) + scale(x_2), data = mod_l2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.35612 -0.53383 -0.02476  0.48399  2.10158
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## scale(x_1)  0.19407     0.07379   2.630  0.00991
## scale(x_2)  0.64478     0.07379   8.738 6.58e-14
##
## scale(x_1) **
## scale(x_2) ***
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Dans un modèle linéaire standardisé simple, le coefficient égale la corrélation.

```
lm(scale(y) ~ scale(x), data = mod_l1) |> summary()
```

```
##
## Call:
## lm(formula = scale(y) ~ scale(x), data = mod_l1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.49102 -0.41415 -0.01586  0.40655  1.32207
##
## Coefficients:
##              Estimate Std. Error t value
## (Intercept) -1.163e-16  6.182e-02   0.00
## scale(x)      7.884e-01  6.214e-02  12.69
##
##      Pr(>|t|)
## (Intercept)      1
## scale(x)        <2e-16 ***
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

La significativité de la corrélation entre deux variables est celle du coefficient de la régression standardisée.

Plus simplement :

```
with(mod_l1, cor.test(x, y))
```

```
##  
## Pearson's product-moment correlation  
##  
## data: x and y  
## t = 12.689, df = 98, p-value < 2.2e-16  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
## 0.7005033 0.8527907  
## sample estimates:  
## cor  
## 0.7884389
```

Régression  
linéaire

Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova

# Régression sur les rangs



Si les résidus ne sont pas normaux, il est possible de faire la régression sur les rangs des variables :

- régression simple : revient à tester la corrélation de Spearman.

## Modèle univarié :

```
lm(rank(y) ~ rank(x), data = mod_l1)|> summary()
```

```
##
## Call:
## lm(formula = rank(y) ~ rank(x), data = mod_l1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -42.203 -11.867   1.019  11.140  41.659
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 10.22667    3.54507   2.885  0.00482
## rank(x)      0.79749    0.06095  13.085 < 2e-16
##
## (Intercept) **
## rank(x)      ***
## ---
## Signif. codes:
## 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 17.59 on 98 degrees of freedom
```

# Ancova

Modèle de régression multiple avec des covariables catégorielles, codées sous forme d'indicatrices (autant d'indicatrices que de modalités - 1).

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + E$$

Exemple du Ventoux :

- $Y$  est la hauteur des arbres ;
- $X_1$  est leur diamètre ;
- L'espèce est codée par une variable indicatrice, par exemple  $X_2 = \mathbb{1}('Cedre')$ .

# Exemple

## Régression linéaire

Eric Marcon


Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova

```
ventoux |>
  ggplot(aes(x = diametre, y = hauteur, color = espece)) +
  geom_point() +
  geom_smooth(method = "lm")
```



La figure représente *deux régressions séparées* : les pentes pourraient être différentes. Une Ancova est donc appropriée.

lm crée automatiquement des indicatrices pour les variables catégorielles.


```
(ventoux_lm <- lm(hauteur ~ diametre + espece, data = ventoux))
```

```
##  
## Call:  
## lm(formula = hauteur ~ diametre + espece, data = ventoux)  
##  
## Coefficients:  
## (Intercept)      diametre      especePin  
##      6.5018      0.2605      -0.7696
```

Ici, l'indicatrice vaut 1 pour les pins, 0 pour les cèdres.

## La figure doit être construite manuellement

```
ventoux |>  
  bind_cols(predict(ventoux_lm, interval = "confidence")) |>  
  ggplot(aes(x = diametre, color = espece)) +  
    geom_point(aes(y = hauteur)) +  
    geom_line(aes(y = fit)) +  
    geom_ribbon(aes(y = fit, ymin = lwr, ymax = upr), alpha = 0.3)
```



## Régression linéaire

Eric Marcon

Régression  
linéaire simple

Régression  
linéaire  
multiple

Régression sur  
les rangs

Ancova